



# Práctica EEG.

Ricardo Hernández V., E. Fabián Rosas E., Denise M. Alonso V.

*Instituto Nacional de Astrofísica, Óptica y Electrónica*

*Maestría en Ciencias y Tecnologías Biomédicas, Laboratorio de instrumentación biomédica.*

## I. Resumen de Datos.

El conjunto de datos disponibles está compuesto de las señales EEG de 27 individuos que fueron registradas durante un experimento de habla imaginada en el cual los sujetos imaginaban cinco movimientos, arriba, abajo, izquierda, derecha y seleccionar. Las señales de EEG fueron muestreadas a 128 Hz, a continuación, se muestra en la Tabla 1 la información de las pruebas realizadas de los tres primeros sujetos.

Sujeto	Palabras imaginadas	Épocas por palabra
Sujeto 1	5	33
Sujeto 2	5	33
Sujeto 3	5	33

*Tabla 1.- Características de los datos para los tres sujetos*

La extracción de características y la clasificación se realiza con los datos de los primeros tres sujetos del conjunto de muestras de EEG disponibles.

## II. Extracción de Características.

Para extraer las características las señales de EEG de cada época se dividieron en ventanas, determinando un número de muestras por ventanas y el avance entre ventanas, en la tabla 2 se describe la división de las señales.

Número de ventanas	Tamaño de ventana	Avance
2 ventanas	60% de las muestras	60% de muestras en la ventana
3 ventanas	50% de las muestras	50% de muestras en la ventana
4 ventanas	40% de las muestras	50% de muestras en la ventana

*Tabla 2.- Descripción de la división de ventanas*

El procesamiento de los datos de las señales de EEG para extraer las características se realizó siguiendo el esquema propuesto en <sup>[1]</sup>, las características extraídas en este proceso son el promedio

de la energía en las bandas delta, theta, alfa, beta y gama de los 14 canales en cada época, por lo cual cada señal de EEG está representada por un vector de características.

El proceso aplicado para el procesamiento de los datos se describe a continuación:

1. Filtrar las señales de cada ventana en la frecuencia de las bandas de interés: Con un filtro pasa-banda butterworth.
2. Elevar al cuadrado la señal resultante para obtener la energía de la señal filtrada.
3. Calcular el promedio por banda de frecuencia en cada ventana.

El proceso de extraer los valores de las 5 bandas en cada ventana para cada canal se aplicó en todas las épocas para las 5 palabras y con cada sujeto, después del procesamiento los vectores con la información de las bandas en cada época para 2 ventanas resultaron de 140 características, para 3 ventanas 210 características y para 4 ventanas 280 características, finalmente se agruparon los 33 vectores con características por cada palabra y se agregó una columna para identificar a qué clase o palabra pertenecían, las palabras se etiquetaron como 1, 2, 3, 4 y 5.

Se realizó otro proceso de extracción de características para obtener la media, desviación estándar, varianza, valor mínimo y máximo por cada banda en cada una de las ventanas, el procesamiento fue similar al descrito anteriormente, en este caso los vectores de características tuvieron más elementos, para 2 ventanas resultaron 700 características, para 3 ventanas 1050 características y para 4 ventanas 1400, finalmente a cada vector se le asignó una etiqueta correspondiente a la palabra que representa.

### III. Clasificación.

Se realizaron dos tipos de clasificación; por máquinas de soporte vectorial y redes neuronales, para el primero se utilizó el software Weka (University of Waikato) en la aplicación *Explorer*, que permite la clasificación de una extracción de características en formato *.ARFF*, por lo cual, fue necesario convertir los archivos obtenidos de la extracción de características a dicho formato por medio de un script en Matlab, el cual también tuvo la función de juntar en una misma matriz las características ya extraídas de cada palabra, dicho proceso se realizó por cada uno de los sujetos analizados en cada una de las modalidades (bandas o datos estadísticos). Dentro de la aplicación *Experimenter* se seleccionó un número aleatorio de muestras para entrenamiento igual al 75% de las repeticiones de las palabras imaginadas para cada clase, mientras el resto se utilizó para prueba. El clasificador de máquina de vectores de soporte (SMV) fue encontrado en *functions* como SMO. De los resultados obtenidos en el software se reportó la exactitud y la matriz de confusión, con la cual es posible visualizar las palabras en las que se obtuvieron errores en las pruebas, este procedimiento se realizó 18 veces, ya que fueron 3 sujetos, con 3 tipos de ventanas aplicadas en datos de las bandas de frecuencia y datos estadísticos. A continuación, en la Tabla 3 se muestran los resultados obtenidos al utilizar 2 ventanas, en la Tabla 4 al utilizar 3 ventanas y en la Tabla 5 para 4 ventanas. Debajo de cada tabla se encuentran las matrices de confusión.

## 2 ventanas 60%, avance 60%

Datos	Sujeto 1	Sujeto 2	Sujeto 3
Bandas	82.93%	43.90%	43.90%
Estadísticos	68.29%	58.54%	48.78%

Tabla 3.- Resultados obtenidos al utilizar 2 ventanas

### Matrices de confusión

#### Bandas de frecuencia

##### Sujeto 1

```
a b c d e  <-- classified
8 0 0 0 0 | a = 1
0 9 0 0 2 | b = 2
0 0 5 2 0 | c = 3
0 2 0 6 0 | d = 4
0 1 0 0 6 | e = 5
```

##### Sujeto 2

```
a b c d e  <-- classified
4 1 1 1 1 | a = 1
6 1 1 0 3 | b = 2
0 0 6 0 1 | c = 3
1 2 4 1 0 | d = 4
0 1 0 0 6 | e = 5
```

##### Sujeto 3

```
a b c d e  <-- classified
5 0 0 2 1 | a = 1
1 4 4 1 1 | b = 2
1 1 2 2 1 | c = 3
1 1 3 3 0 | d = 4
0 1 0 2 4 | e = 5
```

### Datos estadísticos

##### Sujeto 1

```
a b c d e  <-- classified
8 0 0 0 0 | a = 1
0 7 0 2 2 | b = 2
0 1 5 1 0 | c = 3
0 1 2 4 1 | d = 4
0 2 0 1 4 | e = 5
```

##### Sujeto 2

```
a b c d e  <-- classified
7 0 0 0 1 | a = 1
2 1 4 3 1 | b = 2
0 1 6 0 0 | c = 3
1 0 1 4 2 | d = 4
0 0 1 0 6 | e = 5
```

##### Sujeto 3

```
a b c d e  <-- classified
8 0 0 0 0 | a = 1
1 3 5 0 2 | b = 2
0 1 3 1 2 | c = 3
0 2 2 2 2 | d = 4
0 1 1 1 4 | e = 5
```

## 3 ventanas 50%, avance 50%

Datos	Sujeto 1	Sujeto 2	Sujeto 3
Bandas	78.05%	51.22%	48.78%
Estadísticos	75.61%	56.10%	39.02%

Tabla 4.- Resultados obtenidos al utilizar 3 ventanas

### Matrices de confusión

#### Bandas de frecuencia

##### Sujeto 1

```
a b c d e  <-- classified
8 0 0 0 0 | a = 1
0 6 0 0 5 | b = 2
0 0 6 1 0 | c = 3
0 1 1 6 0 | d = 4
0 1 0 0 6 | e = 5
```

##### Sujeto 2

```
a b c d e  <-- classified
4 1 0 1 2 | a = 1
6 2 1 0 2 | b = 2
0 0 6 0 1 | c = 3
1 1 3 3 0 | d = 4
0 0 1 0 6 | e = 5
```

##### Sujeto 3

```
a b c d e  <-- classified
6 0 0 2 0 | a = 1
1 5 3 0 2 | b = 2
0 1 3 2 1 | c = 3
1 2 3 2 0 | d = 4
0 1 0 2 4 | e = 5
```

### Datos estadísticos

Sujeto 1	Sujeto 2	Sujeto 3
a b c d e <-- classified	a b c d e <-- classified	a b c d e <-- classified
8 0 0 0 0   a = 1	5 1 0 1 1   a = 1	8 0 0 0 0   a = 1
0 6 0 0 5   b = 2	1 3 1 2 4   b = 2	2 3 2 1 3   b = 2
0 0 5 2 0   c = 3	0 0 5 1 1   c = 3	0 3 1 1 2   c = 3
0 0 0 6 2   d = 4	1 1 2 3 1   d = 4	0 3 2 1 2   d = 4
0 1 0 0 6   e = 5	0 0 0 0 7   e = 5	0 1 2 1 3   e = 5

4 ventanas 40%, avance 50%

Datos	Sujeto 1	Sujeto 2	Sujeto 3
Bandas	80.49%	48.78%	53.66%
Estadísticos	73.17%	51.22%	43.90%

Tabla 5.- Resultados obtenidos al utilizar 4 ventanas

#### Matrices de confusión

#### Bandas de frecuencia

Sujeto 1	Sujeto 2	Sujeto 3
a b c d e <-- classified	a b c d e <-- classified	a b c d e <-- classified
8 0 0 0 0   a = 1	5 1 0 1 1   a = 1	7 0 1 0 0   a = 1
0 8 0 0 3   b = 2	5 1 2 0 3   b = 2	2 3 3 1 2   b = 2
0 0 6 1 0   c = 3	0 1 4 0 2   c = 3	0 0 4 1 2   c = 3
0 1 2 5 0   d = 4	1 1 3 3 0   d = 4	1 1 2 3 1   d = 4
0 1 0 0 6   e = 5	0 0 0 0 7   e = 5	1 0 1 0 5   e = 5

#### Datos estadísticos

Sujeto 1	Sujeto 2	Sujeto 3
a b c d e <-- classified	a b c d e <-- classified	a b c d e <-- classified
8 0 0 0 0   a = 1	5 0 1 1 1   a = 1	8 0 0 0 0   a = 1
0 7 0 0 4   b = 2	0 3 1 3 4   b = 2	0 3 2 1 5   b = 2
1 1 4 1 0   c = 3	0 0 5 1 1   c = 3	0 3 2 2 0   c = 3
0 1 2 5 0   d = 4	1 1 3 2 1   d = 4	0 3 2 1 2   d = 4
0 1 0 0 6   e = 5	0 1 0 0 6   e = 5	0 1 1 1 4   e = 5

#### IV. Análisis comparativo

Debido a los resultados con bajo porcentaje de asertividad obtenidos en SMV (Maquinas de Vectores de Soporte), se decidió hacer un segundo análisis comparativo para determinar si fue un problema con el método o el software utilizado. Para esto, se decidió de ocupar otro software como lo es *Matlab*, en el se nos permitió crear redes neuronales de cada sujeto de manera rápida y eficaz.

De igual manera se realizó el análisis como se había solicitado en la práctica, con 3 tipos diferentes de ventanas y con diferentes valores de avance para los vectores generados por las frecuencias de bandas y los valores estadísticos de estos. De la Figura 1 a la Figura 9, se muestran las matrices de Confusión con los resultados obtenidos por el análisis de bandas. De los cuales podemos decir que los resultados obtenidos fueron similares, aunque de igual manera inferior a los obtenidos en *Weka* con SMV con los 3 sujetos en los tres tipos de ventanas.

De la Figura 10 a la Figura 18 se muestran los resultados de los análisis estadísticos, los cuales salieron aun menores que los hechos por frecuencias de bandas, tanto de este análisis como el hecho en *Weka*.

A continuación se muestra las Tabla 3, 4 y 5, donde se muestra un resumen de la comparación de los resultados obtenidos en *Weka* y *Matlab*.

Sujeto 1	2 Ventanas	3 Ventanas	4 Ventanas
Weka (Bandas)	<b>82.93%</b>	78.05%	80.49%
Matlab (Bandas)	60%	50%	65%
Weka (Estadísticos)	68.29%	<b>75.61%</b>	73.17%
Matlab (Estadísticos)	37.5%	37.5%	50%

Tabla 3. Comparación de resultados del Sujeto 1

Sujeto 2	2 Ventanas	3 Ventanas	4 Ventanas
Weka (Bandas)	43.90%	<b>51.22%</b>	48.78%
Matlab (Bandas)	17.5%	30%	20%
Weka (Estadísticos)	<b>58.54%</b>	56.1%	51.22%
Matlab (Estadísticos)	32.5%	25%	25%

*Tabla 4. Comparación de resultados del Sujeto 2*

Sujeto 3	2 Ventanas	3 Ventanas	4 Ventanas
Weka (Bandas)	43.9%	48.78%	<b>53.66%</b>
Matlab (Bandas)	35%	30%	15%
Weka (Estadísticos)	<b>48.78%</b>	39.02%	43.9%
Matlab (Estadísticos)	27.5%	30.5%	25%

*Tabla 5. Comparación de resultados del Sujeto 3*

## Análisis por Bandas:

- 2 ventanas, traslape de 60%

Confusion Matrix

Output Class \ Target Class	1	2	3	4	5	
1	8 20.0%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
2	1 2.5%	6 15.0%	0 0.0%	1 2.5%	0 0.0%	75.0% 25.0%
3	0 0.0%	1 2.5%	6 15.0%	1 2.5%	0 0.0%	75.0% 25.0%
4	0 0.0%	1 2.5%	3 7.5%	4 10.0%	0 0.0%	50.0% 50.0%
5	8 20.0%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	0.0% 100%
	47.1% 52.9%	75.0% 25.0%	66.7% 33.3%	66.7% 33.3%	NaN% NaN%	60.0% 40.0%

Figura 3. Sujeto 1 a 2 ventanas con 60%

Confusion Matrix

Output Class \ Target Class	1	2	3	4	5	
1	0 0.0%	7 17.5%	0 0.0%	1 2.5%	0 0.0%	0.0% 100%
2	0 0.0%	6 15.0%	2 5.0%	0 0.0%	0 0.0%	75.0% 25.0%
3	0 0.0%	7 17.5%	1 2.5%	0 0.0%	0 0.0%	12.5% 87.5%
4	1 2.5%	6 15.0%	1 2.5%	0 0.0%	0 0.0%	0.0% 100%
5	0 0.0%	8 20.0%	0 0.0%	0 0.0%	0 0.0%	0.0% 100%
	0.0% 100%	17.6% 82.4%	25.0% 75.0%	0.0% 100%	NaN% NaN%	17.5% 82.5%

Figura 2. Sujeto 2 a 2 ventanas con 60%

Confusion Matrix

Output Class \ Target Class	1	2	3	4	5	
1	2 5.0%	0 0.0%	1 2.5%	4 10.0%	1 2.5%	25.0% 75.0%
2	0 0.0%	3 7.5%	1 2.5%	3 7.5%	1 2.5%	37.5% 62.5%
3	0 0.0%	1 2.5%	0 0.0%	6 15.0%	1 2.5%	0.0% 100%
4	0 0.0%	0 0.0%	0 0.0%	7 17.5%	1 2.5%	87.5% 12.5%
5	3 7.5%	0 0.0%	0 0.0%	3 7.5%	2 5.0%	25.0% 75.0%
	40.0% 60.0%	75.0% 25.0%	0.0% 100%	30.4% 69.6%	33.3% 66.7%	35.0% 65.0%

Figura 1. Sujeto 3 a 2ventanas con 60%

- 3 Ventanas, traslape de 50%

Confusion Matrix

Output Class \ Target Class	1	2	3	4	5	
1	7 17.5%	0 0.0%	0 0.0%	1 2.5%	0 0.0%	87.5% 12.5%
2	0 0.0%	4 10.0%	0 0.0%	3 7.5%	1 2.5%	50.0% 50.0%
3	0 0.0%	0 0.0%	7 17.5%	1 2.5%	0 0.0%	87.5% 12.5%
4	0 0.0%	2 5.0%	4 10.0%	2 5.0%	0 0.0%	25.0% 75.0%
5	8 20.0%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	0.0% 100%
	46.7% 53.3%	66.7% 33.3%	63.6% 36.4%	28.6% 71.4%	0.0% 100%	50.0% 50.0%

Figura 5. Sujeto 1 a 3 ventanas con 50%

Confusion Matrix

Output Class \ Target Class	1	2	3	4	5	
1	6 15.0%	0 0.0%	0 0.0%	1 2.5%	1 2.5%	75.0% 25.0%
2	4 10.0%	0 0.0%	1 2.5%	3 7.5%	0 0.0%	0.0% 100%
3	0 0.0%	0 0.0%	3 7.5%	5 12.5%	0 0.0%	37.5% 62.5%
4	3 7.5%	0 0.0%	2 5.0%	3 7.5%	0 0.0%	37.5% 62.5%
5	8 20.0%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	0.0% 100%
	28.6% 71.4%	NaN% NaN%	50.0% 50.0%	25.0% 75.0%	0.0% 100%	30.0% 70.0%

Figura 4. Sujeto 2 a 3 ventanas con 50%

Confusion Matrix

Output Class \ Target Class	1	2	3	4	5	
1	0 0.0%	3 7.5%	0 0.0%	1 2.5%	4 10.0%	0.0% 100%
2	0 0.0%	7 17.5%	0 0.0%	1 2.5%	0 0.0%	87.5% 12.5%
3	0 0.0%	3 7.5%	0 0.0%	4 10.0%	1 2.5%	0.0% 100%
4	0 0.0%	3 7.5%	0 0.0%	3 7.5%	2 5.0%	37.5% 62.5%
5	0 0.0%	5 12.5%	0 0.0%	1 2.5%	2 5.0%	25.0% 75.0%
	NaN% NaN%	33.3% 66.7%	NaN% NaN%	30.0% 70.0%	22.2% 77.8%	30.0% 70.0%

Figura 6. Sujeto 3 a 3 ventanas con 50 %

- 4 Ventanas, traslape de 50%

Confusion Matrix

Output Class \ Target Class	1	2	3	4	5	
1	7 17.5%	0 0.0%	0 0.0%	0 0.0%	1 2.5%	87.5% 12.5%
2	0 0.0%	7 17.5%	1 2.5%	0 0.0%	0 0.0%	87.5% 12.5%
3	0 0.0%	0 0.0%	8 20.0%	0 0.0%	0 0.0%	100% 0.0%
4	0 0.0%	1 2.5%	2 5.0%	3 7.5%	2 5.0%	37.5% 62.5%
5	7 17.5%	0 0.0%	0 0.0%	0 0.0%	1 2.5%	12.5% 87.5%
	50.0% 50.0%	87.5% 12.5%	72.7% 27.3%	100% 0.0%	25.0% 75.0%	65.0% 35.0%

Figura 9. Sujeto 1 a 4 ventanas con 50%

Confusion Matrix

Output Class \ Target Class	1	2	3	4	5	
1	3 7.5%	2 5.0%	3 7.5%	0 0.0%	0 0.0%	37.5% 62.5%
2	1 2.5%	1 2.5%	1 2.5%	2 5.0%	3 7.5%	12.5% 87.5%
3	1 2.5%	0 0.0%	1 2.5%	2 5.0%	4 10.0%	12.5% 87.5%
4	1 2.5%	0 0.0%	3 7.5%	3 7.5%	1 2.5%	37.5% 62.5%
5	4 10.0%	2 5.0%	2 5.0%	0 0.0%	0 0.0%	0.0% 100%
	30.0% 70.0%	20.0% 80.0%	10.0% 90.0%	42.9% 57.1%	0.0% 100%	20.0% 80.0%

Figura 8. Sujeto2 a 4 ventanas con 50%

Confusion Matrix

Output Class \ Target Class	1	2	3	4	5	
1	0 0.0%	1 2.5%	0 0.0%	5 12.5%	2 5.0%	0.0% 100%
2	0 0.0%	1 2.5%	1 2.5%	4 10.0%	2 5.0%	12.5% 87.5%
3	0 0.0%	1 2.5%	1 2.5%	4 10.0%	2 5.0%	12.5% 87.5%
4	0 0.0%	0 0.0%	2 5.0%	3 7.5%	3 7.5%	37.5% 62.5%
5	0 0.0%	1 2.5%	0 0.0%	6 15.0%	1 2.5%	12.5% 87.5%
	NaN% NaN%	25.0% 75.0%	25.0% 75.0%	13.6% 86.4%	10.0% 90.0%	15.0% 85.0%

Figura 7. Sujeto 3 a 4ventanas con 50%

- 2 ventanas, traslape de 60%

Confusion Matrix

1	4 10.0%	0 0.0%	1 2.5%	0 0.0%	3 7.5%	50.0% 50.0%
2	2 5.0%	2 5.0%	0 0.0%	4 10.0%	0 0.0%	25.0% 75.0%
3	1 2.5%	0 0.0%	5 12.5%	2 5.0%	0 0.0%	62.5% 37.5%
4	0 0.0%	1 2.5%	4 10.0%	3 7.5%	0 0.0%	37.5% 62.5%
5	7 17.5%	0 0.0%	0 0.0%	0 0.0%	1 2.5%	12.5% 87.5%
	28.6% 71.4%	66.7% 33.3%	50.0% 50.0%	33.3% 66.7%	25.0% 75.0%	37.5% 62.5%
	1	2	3	4	5	

Output Class

Target Class

Figura 10. Sujeto 1 a 2 ventanas con 60% (estadístico)

Confusion Matrix

1	3 7.5%	3 7.5%	1 2.5%	0 0.0%	1 2.5%	37.5% 62.5%
2	1 2.5%	4 10.0%	0 0.0%	3 7.5%	0 0.0%	50.0% 50.0%
3	0 0.0%	0 0.0%	4 10.0%	3 7.5%	1 2.5%	50.0% 50.0%
4	3 7.5%	2 5.0%	2 5.0%	0 0.0%	1 2.5%	0.0% 100%
5	2 5.0%	2 5.0%	2 5.0%	0 0.0%	2 5.0%	25.0% 75.0%
	33.3% 66.7%	36.4% 63.6%	44.4% 55.6%	0.0% 100%	40.0% 60.0%	32.5% 67.5%
	1	2	3	4	5	

Output Class

Target Class

Figura 11. Sujeto 2 a 2 ventanas con 60% (estadístico)

Confusion Matrix

1	3 7.5%	5 12.5%	0 0.0%	0 0.0%	0 0.0%	37.5% 62.5%
2	2 5.0%	6 15.0%	0 0.0%	0 0.0%	0 0.0%	75.0% 25.0%
3	1 2.5%	3 7.5%	1 2.5%	1 2.5%	2 5.0%	12.5% 87.5%
4	1 2.5%	1 2.5%	3 7.5%	1 2.5%	2 5.0%	12.5% 87.5%
5	5 12.5%	3 7.5%	0 0.0%	0 0.0%	0 0.0%	0.0% 100%
	25.0% 75.0%	33.3% 66.7%	25.0% 75.0%	50.0% 50.0%	0.0% 100%	27.5% 72.5%
	1	2	3	4	5	

Output Class

Target Class

Figura 12. Sujeto 3 a 2 ventanas con 60% (estadístico)

- 3 Ventanas, traslape de 50%

Confusion Matrix

1	6 15.0%	1 2.5%	0 0.0%	0 0.0%	1 2.5%	75.0% 25.0%
2	1 2.5%	1 2.5%	0 0.0%	2 5.0%	4 10.0%	12.5% 87.5%
3	1 2.5%	0 0.0%	6 15.0%	1 2.5%	0 0.0%	75.0% 25.0%
4	1 2.5%	0 0.0%	3 7.5%	2 5.0%	2 5.0%	25.0% 75.0%
5	7 17.5%	1 2.5%	0 0.0%	0 0.0%	0 0.0%	0.0% 100%
	37.5% 62.5%	33.3% 66.7%	66.7% 33.3%	40.0% 60.0%	0.0% 100%	37.5% 62.5%
	1	2	3	4	5	

Output Class

Target Class

Figura 13- Sujeto 1 a 3 ventanas con 50 % (estadístico)

Confusion Matrix

1	4 10.0%	2 5.0%	0 0.0%	0 0.0%	2 5.0%	50.0% 50.0%
2	2 5.0%	3 7.5%	0 0.0%	2 5.0%	1 2.5%	37.5% 62.5%
3	1 2.5%	1 2.5%	0 0.0%	0 0.0%	6 15.0%	0.0% 100%
4	2 5.0%	2 5.0%	2 5.0%	2 5.0%	0 0.0%	25.0% 75.0%
5	3 7.5%	3 7.5%	0 0.0%	1 2.5%	1 2.5%	12.5% 87.5%
	33.3% 66.7%	27.3% 72.7%	0.0% 100%	40.0% 60.0%	10.0% 90.0%	25.0% 75.0%
	1	2	3	4	5	

Output Class

Target Class

Figura 14. Sujeto 2 a 3 ventanas con 50% (estadístico)

Confusion Matrix

1	4 10.0%	1 2.5%	1 2.5%	2 5.0%	0 0.0%	50.0% 50.0%
2	1 2.5%	6 15.0%	0 0.0%	1 2.5%	0 0.0%	75.0% 25.0%
3	0 0.0%	6 15.0%	0 0.0%	2 5.0%	0 0.0%	0.0% 100%
4	1 2.5%	4 10.0%	0 0.0%	3 7.5%	0 0.0%	37.5% 62.5%
5	6 15.0%	1 2.5%	0 0.0%	1 2.5%	0 0.0%	0.0% 100%
	33.3% 66.7%	33.3% 66.7%	0.0% 100%	33.3% 66.7%	NaN% NaN%	32.5% 67.5%
	1	2	3	4	5	

Output Class

Target Class

Figura 15. Sujeto 3 a 3 ventanas con 50% (estadístico)

- 4 Ventanas, traslape de 50%

Confusion Matrix

1	8 20.0%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
2	2 5.0%	4 10.0%	1 2.5%	1 2.5%	0 0.0%	50.0% 50.0%
3	1 2.5%	0 0.0%	6 15.0%	1 2.5%	0 0.0%	75.0% 25.0%
4	1 2.5%	2 5.0%	2 5.0%	2 5.0%	1 2.5%	25.0% 75.0%
5	8 20.0%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	0.0% 100%
	40.0% 60.0%	66.7% 33.3%	66.7% 33.3%	50.0% 50.0%	0.0% 100%	50.0% 50.0%
	1	2	3	4	5	

Output Class

Target Class

Figura 18. Sujeto 1 a 4 ventanas con 50% (estadístico)

Confusion Matrix

1	3 7.5%	1 2.5%	2 5.0%	2 5.0%	0 0.0%	37.5% 62.5%
2	2 5.0%	2 5.0%	0 0.0%	2 5.0%	2 5.0%	25.0% 75.0%
3	0 0.0%	4 10.0%	2 5.0%	0 0.0%	2 5.0%	25.0% 75.0%
4	1 2.5%	2 5.0%	1 2.5%	3 7.5%	1 2.5%	37.5% 62.5%
5	5 12.5%	1 2.5%	2 5.0%	0 0.0%	0 0.0%	0.0% 100%
	27.3% 72.7%	20.0% 80.0%	28.6% 71.4%	42.9% 57.1%	0.0% 100%	25.0% 75.0%
	1	2	3	4	5	

Output Class

Target Class

Figura 17. Sujeto 2 a 4 ventanas con 50% (estadístico)

Confusion Matrix

1	3 7.5%	0 0.0%	1 2.5%	3 7.5%	1 2.5%	37.5% 62.5%
2	0 0.0%	1 2.5%	2 5.0%	4 10.0%	1 2.5%	12.5% 87.5%
3	0 0.0%	2 5.0%	3 7.5%	3 7.5%	0 0.0%	37.5% 62.5%
4	0 0.0%	1 2.5%	3 7.5%	3 7.5%	1 2.5%	37.5% 62.5%
5	4 10.0%	0 0.0%	1 2.5%	3 7.5%	0 0.0%	0.0% 100%
	42.9% 57.1%	25.0% 75.0%	30.0% 70.0%	18.8% 81.3%	0.0% 100%	25.0% 75.0%
	1	2	3	4	5	

Output Class

Target Class

Figura 16. Sujeto 3 a 4 ventanas con 50% (estadístico)



## VI. Conclusiones

Para realizar la división de las señales de EEG en ventanas se consideró definir el tamaño de ventana con un número de muestras igual para todas las épocas disponibles de las palabras en todos los sujetos, sin embargo después de revisar las épocas se determinó que no tenían la misma cantidad de muestras y utilizar un valor constante del tamaño de ventanas no permitiría realizar la división correctamente, por esto se utilizó el porcentaje del número de muestras en cada época para dividir por ventanas y también un porcentaje para el desplazamiento entre ventanas.

Para la clasificación en Weka primero se probó utilizando el algoritmo k-vecinos más cercanos (K-NN), sin embargo, se observó menor porcentaje de exactitud que con SVM, por lo tanto este fue el utilizado. El porcentaje de exactitud del sujeto 1 en el análisis por bandas de frecuencia estuvo en el rango de 78.05% a 82.93%, los porcentajes más altos se obtuvieron con este sujeto, en este tipo de análisis. En los sujetos 2 y 3 se obtuvo un rango entre 43.90% a 58.54% el cual involucra los dos tipos de datos analizados.

De acuerdo a los resultados obtenidos en las matrices de confusión generadas a partir de SVM, se observó que la primera palabra (arriba) en el sujeto 1 no tuvo ningún error en la etapa de entrenamiento, lo cual podría deberse a que el sujeto al momento de comenzar el experimento se encontraba concentrado en la actividad.

Una vez realizado el análisis comparativo, pudimos llegar a la conclusión que el parámetro de mayor peso no fue el tipo de método de clasificación, si no la poca cantidad de datos utilizados para los entrenamientos.

Aunque el método de clasificación no fue el factor clave para los resultados, si se pudieron observar diferencias considerables, esto debido a que en una red feedforward backpropagation se realizan varias realimentaciones hacia atrás del error calculado, por lo que la cantidad de datos resultó ser aún más ineficiente.

## VII. Referencias

[1] Lotte, F. (2006, September). The use of fuzzy inference systems for classification in EEG-based brain-computer interfaces. In 3rd International Brain-Computer Interfaces Workshop and Training Course.